

# Analyse de Tendances Cinématographiques & Recommandation IA

Projet : Cadre Logiciel pour le Big Data

Bademba SANGARÉ

Master Informatique & Big Data  
Université Paris 8

**Professeur** : Mme Rakia JAZIRI

Janvier 2026

# Sommaire

- 1 Introduction & Objectifs
- 2 Architecture Infrastructure (GCP)
- 3 Data Engineering & Enrichissement
- 4 Traitement Distribué (Hive)
- 5 Module IA : Recommandation
- 6 Démonstration & Analyse
- 7 Conclusion


# Genèse du projet

## L'inspiration "YouTube Recap" :

- Comment traiter des milliards de logs ?
- Comment générer des tendances personnalisées ?

## Objectifs du projet :

- 1 Déployer une architecture **Hadoop** complète (Cloud).
- 2 Ingérer et traiter un large volume de données (MovieLens).
- 3 Développer un module **Data Science** (NLP).
- 4 Restituer les résultats via un Dashboard Web.



# Infrastructure Cloud (IaaS)

Plateforme : Google Cloud Platform (Compute Engine)

## Configuration du Cluster (3 Nœuds)

- **OS** : Ubuntu 22.04 LTS
- **Ressources** : 2 vCPU, 8 Go RAM par nœud
- **Topologie** : 1 Master + 2 Slaves

Instances de VM

Filtrer Saisissez le nom ou la valeur de la propriété

| <input type="checkbox"/> État | Nom ↑                         | Zone          | Recommandations | Utilisé par | Adresse IP interne                  | Adresse IP externe                                      | Connecter |
|-------------------------------|-------------------------------|---------------|-----------------|-------------|-------------------------------------|---------------------------------------------------------|-----------|
| <input type="checkbox"/>      | <a href="#">hadoop-master</a> | us-central1-a |                 |             | 10.128.0.3 ( <a href="#">nic0</a> ) | <a href="#">34.121.158.103</a> ( <a href="#">nic0</a> ) | SSH ▾     |
| <input type="checkbox"/>      | <a href="#">hadoop-slave1</a> | us-central1-a |                 |             | 10.128.0.4 ( <a href="#">nic0</a> ) | <a href="#">136.112.190.65</a> ( <a href="#">nic0</a> ) | SSH ▾     |
| <input type="checkbox"/>      | <a href="#">hadoop-slave2</a> | us-central1-a |                 |             | 10.128.0.5 ( <a href="#">nic0</a> ) | <a href="#">34.55.36.249</a> ( <a href="#">nic0</a> )   | SSH ▾     |

Actions associées

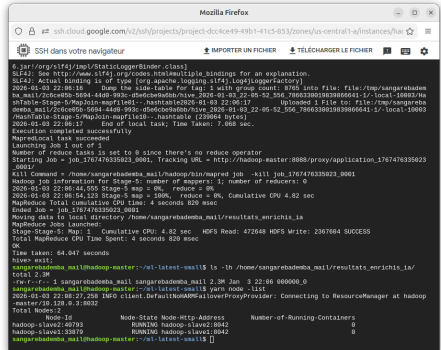
# L'Écosystème Hadoop déployé

## Répartition des Rôles :

- **Master** : NameNode, ResourceManager, Hive Server.
- **Slaves** : DataNodes, NodeManagers.

## Sécurité & Réseau :

- Configuration VPC interne.
- Pare-feu : Ouverture port **8501** (Streamlit).



```
6.jar/org.apache.hadoop.mapreduce.lib.map/StaticLoggerBinder.class]
SLF4J: See http://www.slf4j.org/codes.html#multiple_bindings for an explanation.
SLF4J: Actual binding is of type [org.apache.logging.slf4j.Log4jLoggerFactory]
2026-01-03 22:06:14 Data line side-table for Tag: 1 with group count: 8765 into file: file:/tmp/sangarebademba_mail/2026-01-03-22:06:14-0000-9930-d56c0e9eb0a1/hive_2026-01-03-22:06:14-0000-9930-d56c0e9eb0a1-1/local-150003/HashTable-Stage-5/MapJoin-mapper10-1-hashtable2026-01-03-22:06:14-0000-9930-d56c0e9eb0a1-1/local-15003/HashTable-Stage-5/MapJoin-mapper10-1-hashtable (239064 bytes)
2026-01-03 22:06:17 End of local task; Time Taken: 7.068 sec.
Execution completed successfully
MapredLocal task succeeded
Launching Job 1 out of 1
Number of reduce tasks is set to 0 since there's no reduce operator
Starting Job = job_1767476335023_0001, Tracking URL = http://hadoop-master:8088/proxy/application_1767476335023_0001/
Kill Command = /home/sangarebademba_mail/hadoop/bin/mapred job -kill job_1767476335023_0001
Hadoop job information for Stage-5: number of mappers: 1; number of reducers: 0
2026-01-03 22:06:04,050 Stage-5 map = 0%, reduce = 0%
2026-01-03 22:06:54,123 Stage-5 map = 100%, reduce = 0%, Cumulative CPU 4.82 sec
MapReduce Total cumulative CPU time: 4 seconds 820 msec
Ended Job = job_1767476335023_0001
Moving data to local directory /home/sangarebademba_mail/resultsats_enrichis_1a
MapReduce Jobs Launched:
Stage:Stage-5: Map: 1, Cumulative CPU: 4.82 sec HDFS Read: 472648 HDFS Write: 2367604 SUCCESS
Total MapReduce CPU Time Spent: 4 seconds 820 msec
OK
Time taken: 64.047 seconds
hive> exit!
sangarebademba_mail@hadoop-master:~/l1-test-sma15 $ ls -lh /home/sangarebademba_mail/resultsats_enrichis_1a/
total 2.3M
-rw-r--r-- 1 sangarebademba_mail sangarebademba_mail 2.3M Jan 3 22:06 000000_0
sangarebademba_mail@hadoop-master:~/l1-test-sma15 $ yarn node -list
2026-01-03 22:08:27,258 INFO Client.DefaultHadoopMailoverProxyProvider: Connecting to ResourceManager at hadoop-master/10.128.0.3:8032
Total Nodes:2
Node-1d Node-State Node-Http-Address Number-of-Running-Containers
hadoop-slave2:80793 RUNNING hadoop-slave2:8042 0
hadoop-slave1:33879 RUNNING hadoop-slave1:8042 0
sangarebademba_mail@hadoop-master:~/l1-test-sma15 $
```

Preuve : yarn node -list (2 nœuds actifs)

# Sources de Données

**Le défi** : MovieLens contient des notes, mais pas d'images ni de résumés.


| Fichier     | Contenu             | Source                |
|-------------|---------------------|-----------------------|
| movies.csv  | ID, Titre, Genre    | MovieLens (Local)     |
| ratings.csv | 100k Votes          | MovieLens (Local)     |
| links.csv   | <b>Pont ID TMDb</b> | MovieLens (Local)     |
| api_data    | Affiches, Résumés   | <b>API TMDb (Web)</b> |

## Stratégie d'Enrichissement

Utilisation d'un script Python hybride pour ne télécharger **que** les métadonnées manquantes via l'API, en utilisant `links.csv` comme table de jointure.

# Ingestion HDFS

Toutes les données structurées sont envoyées dans le système de fichiers distribué.



```
sangarebademba_mail@hadoop-master:~$ ls
hadoop
sangarebademba_mail@hadoop-master:~$ wget https://files.grouplens.org/datasets/movielens/ml-latest-small.zip
--2026-01-02 21:11:30-- https://files.grouplens.org/datasets/movielens/ml-latest-small.zip
Resolving files.grouplens.org (files.grouplens.org)... 128.101.96.204
Connecting to files.grouplens.org (files.grouplens.org)|128.101.96.204|:443... connected.
HTTP request sent, awaiting response... 200 OK
Length: 978202 (955K) [application/zip]
Saving to: 'ml-latest-small.zip'

ml-latest-small.zip      100%[=====] 955.28K  --.-KB/s  in 0.1s

2026-01-02 21:11:30 (6.98 MB/s) - 'ml-latest-small.zip' saved [978202/978202]

sangarebademba_mail@hadoop-master:~$ ls
hadoop ml-latest-small.zip
sangarebademba_mail@hadoop-master:~$ unzip ml-latest-small.zip
Archive: ml-latest-small.zip
  creating: ml-latest-small/
  inflating: ml-latest-small/links.csv
  inflating: ml-latest-small/tags.csv
  inflating: ml-latest-small/ratings.csv
  inflating: ml-latest-small/README.txt
  inflating: ml-latest-small/movies.csv
sangarebademba_mail@hadoop-master:~$ ls
hadoop ml-latest-small ml-latest-small.zip
sangarebademba_mail@hadoop-master:~$ ls -l
total 964
drwxr-xr-x 13 sangarebademba_mail sangarebademba_mail 4096 Jan  1 22:05 hadoop
drwxr-xr-x  2 sangarebademba_mail sangarebademba_mail 4096 Sep 26 2018 ml-latest-small
-rw-rw-r-- 1 sangarebademba_mail sangarebademba_mail 978202 Dec  3 2019 ml-latest-small.zip
sangarebademba_mail@hadoop-master:~$ hdfs dfs -mkdir -p /input
sangarebademba_mail@hadoop-master:~$ hdfs dfs -put ml-latest-small/movies.csv /input/
sangarebademba_mail@hadoop-master:~$ hdfs dfs -put ml-latest-small/ratings.csv /input/
sangarebademba_mail@hadoop-master:~$ hdfs dfs -ls /input/
Found 2 items
-rw-r--r--  2 sangarebademba_mail supergroup 494431 2026-01-02 21:13 /input/movies.csv
```

# La "Grande Jointure" Hive

Fusion des données historiques et des données API via HiveQL.


```
SELECT
    m.title,
    t.description,
    t.cover_url,
    avg(r.rating) as avg_score
FROM movies m
JOIN links l ON m.movieId = l.movieId
JOIN tmdb_data t ON l.tmdbId = t.tmdb_id
JOIN ratings r ON m.movieId = r.movieId
GROUP BY m.title, t.description, t.cover_url;
```

Cette requête déclenche un job **MapReduce** complet sur le cluster.



# Exécution MapReduce

Vue de l'exécution du job sur les nœuds esclaves.



```
Peak Reduce Physical memory (bytes)=243900416
Peak Reduce Virtual memory (bytes)=2547544064
Shuffle Errors
BAD_ID=0
CONNECTION=0
IO_ERROR=0
WRONG_LENGTH=0
WRONG_MAP=0
WRONG_REDUCE=0
File Input Format Counters
  Bytes Read=498527
File Output Format Counters
  Bytes Written=461100
2026-01-02 21:40:51,119 INFO streaming.StreamJob: Output directory: /cleaned_data
sangarebademba_mail@hadoop-master:~$ hdfs dfs -head /cleaned_data/part-00000
1      Toy Story      1995      Adventure|Animation|Children|Comedy|Fantasy
10     GoldenEye      1995      Action|Adventure|Thriller
100    City Hall        1996      Drama|Thriller
100044 Human Planet      2011      Documentary
100068 Comme un chef     2012      Comedy
100083 Movie 43           2013      Comedy
100106 Pervert's Guide to Ideology, The 2012      Documentary
100159 Sightseers       2012      Comedy
100163 Hansel & Gretel: Witch Hunters 2013      Action|Fantasy|Horror|IMAX
100194 Jim Jefferies: Fully Functional (EPIX) 2012      Comedy
100226 Why Stop Now      2012      Comedy|Drama
100277 Tabu             2012      Drama|Romance
1003    Extreme Measures   1996      Drama|Thriller
100302 Upside Down        2012      Drama|Romance|Sci-Fi
100304 Liability, The     2012      Action|Thriller
100306 Angst             1983      Drama|Horror
100326 Stand Up Guys      2012      Comedy|Crime
100383 Side Effects       2013      Crime|Drama|Mystery|Thriller
100390 Identity Thief     2013      Comedy|Crime
100397 ABCs of Death, The 2012      Horror
1004    Glimmer Man, The   1996      Action|Thriller
100487 Beautiful Creatures 2013      Drama|Fantasy|Romance
```

# Moteur de Recommandation NLP

**Objectif :** Recommander des films similaires basés sur le *contenu du résumé* (Content-Based Filtering), et non sur les notes.

## 1. TF-IDF (Vectorisation)

- Transforme le texte en vecteurs.
- Pénalise les mots courants ("le", "de").
- Valorise les mots clés ("Espace", "Mafia").

## 2. Similarité Cosinus

- Calcule l'angle entre deux vecteurs films.
- Score de 0 à 1 (1 = Identique).

*Intégré directement dans le Dashboard Python.*

# Analyse : KPIs et Tendances

- **Dominance** : Drame (19.7%) et Comédie (17%) sont les genres les plus représentés.
- **Activité** : Distribution en "loi de puissance" (Power Law). Quelques utilisateurs (ex : User 414) génèrent une part massive des interactions.

*(Voir démonstration live pour les graphiques interactifs)*

# Analyse : Évolution Temporelle

- Explosion de la production cinématographique recensée à partir des années 1990.
- Pic d'activité dans les années 2000-2010.
- Corrélation directe avec la démocratisation du cinéma numérique.

*(Voir démonstration live pour la courbe temporelle)*

# Démonstration Vidéo *Passage sur*

*l'interface Streamlit...*

# Bilan du Projet

## Compétences Acquisées

- **Infrastructure Cloud** : Gestion autonome de VMs et Budget GCP.
- **Hadoop Stack** : HDFS, YARN, Hive en environnement distribué.
- **Data Engineering** : Pipeline ETL hybride (CSV + API).
- **Data Science** : Intégration IA/NLP dans une application Big Data.

Le projet "Cinema Trends" est une chaîne de valeur complète de la donnée brute à l'utilisateur final.

# Merci de votre attention.

**Bademba SANGARÉ**  
M1 Informatique & Big Data