

Rapport de Projet Big Data

Cadre Logiciel pour le Big Data (Hadoop, MapReduce, Hive, YARN)

Sujet :


Analyse de Tendances Cinématographiques + Recommandations de Films (NLP)

🏆 Top 10 des Meilleurs Films (> 50 votes)

Titre	Genres	Note Moyenne	Nombre de Votes
0 Shawshank Redemption, The	Crime/Drama	4.43	317
1 Godfather, The	Crime/Drama	4.29	192
2 Fight Club	Action/Crime/Drama/Thriller	4.27	218
3 Cool Hand Luke	Drama	4.27	57
4 Dr. Strangelove or: How I Learned to Stop Worrying and Love the Bomb	Comedy/War	4.27	97
5 Rear Window	Mystery/Thriller	4.26	84
6 Godfather: Part II, The	Crime/Drama	4.26	129
7 Departed, The	Crime/Drama/Thriller	4.25	107
8 GoodFellas	Crime/Drama	4.25	126
9 Casablanca	Drama/Romance	4.24	100


🍿 Répartition des Genres

Quels genres dominent ?



👤 Top 10 Utilisateurs Actifs

Qui vote le plus ?



Bademba SANGARÉ
M1 Informatique et Big Data

Janvier 2026

Professeur : Mme Rakia JAZIRI

Table des matières

1	Introduction	3
1.1	Genèse du Projet : L'inspiration "YouTube Recap"	3
1.2	Objectifs du Module	3
2	Données et Enrichissement (Data Engineering)	4
2.1	Structure des Données Sources	4
2.2	Stratégie d'Enrichissement via API	4
3	Architecture Infrastructure (GCP)	5
3.1	Cluster Hadoop Distribué	5
3.2	Réseau et Sécurité	6
4	Traitement Big Data (Hive MapReduce)	8
4.1	Ingestion HDFS	8
4.2	La "Grande Jointure" Hive	9
5	IA Visualisation (Le Dashboard)	10
5.1	Interface Streamlit et Analyse des Résultats	10
5.1.1	1. KPIs et Qualité	10
5.1.2	2. Répartition des Genres et Activité	10
5.1.3	3. Analyse Temporelle	10
5.2	Système de Recommandation NLP	10
6	Conclusion	11

Accès au Projet

L'application développée dans le cadre de ce projet est actuellement déployée sur un cluster Google Cloud et accessible publiquement :

Lien d'accès au Dashboard Streamlit

<http://34.121.158.103:8501/>

Chapitre 1

Introduction

1.1 Genèse du Projet : L'inspiration "YouTube Recap"

L'idée originale de ce projet est née d'une curiosité technique concernant les célèbres "Rétrospectives de fin d'année" (comme le *YouTube Recap* ou *Spotify Wrapped*).

En voyant ces résumés annuels, je me suis posé une question fondamentale d'ingénierie :

"Comment ces plateformes parviennent-elles à traiter des milliards de logs de visionnage pour générer des rapports de tendances personnalisés pour chaque utilisateur, le tout de manière fluide ?"

C'est pour répondre à cette problématique de scalabilité et comprendre les mécanismes sous-jacents (ingestion massive, traitement distribué, agrégation) que j'ai conçu le projet **"Cinema Trends"**.

1.2 Objectifs du Module

Dans le cadre du module "Cadre logiciel pour le Big Data", l'objectif académique était de déployer une architecture distribuée complète capable de reproduire ce type de traitement à l'échelle.

Au-delà de la simple analyse statistique (Business Intelligence), j'ai souhaité enrichir ce projet avec une dimension Data Science en implémentant un système de recommandation basé sur l'IA (NLP).

Le projet couvre ainsi l'intégralité du cycle de vie de la donnée :

1. **Infrastructure** : Déploiement d'un cluster Hadoop sur le Cloud (GCP).
2. **Enrichissement** : Croisement de données locales (MovieLens) et distantes (API TMDB).
3. **Traitement** : Calculs distribués via Hive et MapReduce.
4. **IA Visualisation** : Moteur de recommandation et Dashboard interactif.

Chapitre 2

Données et Enrichissement (Data Engineering)

Le point de départ est le jeu de données public *MovieLens*, réputé pour la qualité de ses notes, mais pauvre en métadonnées visuelles (pas d'images, pas de résumés).

2.1 Structure des Données Sources

Voici les fichiers bruts utilisés :

- **movies.csv** : Le catalogue de base (ID, Titre, Genres).
- **ratings.csv** : Les 100k votes utilisateurs.
- **links.csv** : **Le fichier clé du projet**. Il contient la correspondance entre l'ID MovieLens et l'ID TMDb (The Movie Database).

2.2 Stratégie d'Enrichissement via API

Pour proposer une expérience utilisateur moderne avec des affiches de films et des résumés, j'ai dû enrichir les données.

L'enjeu technique : Il est inutile et coûteux de tout re-télécharger. J'ai donc développé un script Python hybride qui utilise `links.csv` comme "pont". Le script conserve les données locales (Titre, Date, Genre) pour optimiser le traitement et n'interroge l'API TMDb que pour les données manquantes.

Le fichier final généré, `descriptions_api_tmdb.csv`, possède la structure suivante (épurée des redondances) :

Structure du fichier enrichi (CSV)

```
tmdb_id, description, tmdb_url, cover_url, vote_average, vote_count,  
original_language, popularity
```

Ce fichier a ensuite été ingéré dans HDFS pour être joint aux données MovieLens.

Chapitre 3

Architecture Infrastructure (GCP)

3.1 Cluster Hadoop Distribué

J'ai déployé un cluster de 3 machines virtuelles sur Google Cloud Platform (Compute Engine).




FIGURE 3.1 – Figure 3.1 – Vue de la console GCP : 1 Master et 2 Slaves

Configuration des Nœuds :

- **hadoop-master (10.128.0.3)** : NameNode, ResourceManager, Hive, Streamlit.
- **hadoop-slave1 (10.128.0.4)** : DataNode, NodeManager.
- **hadoop-slave2 (10.128.0.5)** : DataNode, NodeManager.

Une vérification via la commande `yarn node -list` confirme que les deux esclaves sont bien opérationnels et prêts à recevoir des tâches :

```
6.jar!/org.slf4j/impl/StaticLoggerBinder.class]
SLF4J: See http://www.slf4j.org/codes.html#multiple_bindings for an explanation.
SLF4J: Actual binding is of type [org.apache.logging.slf4j.Log4jLoggerFactory]
2026-01-03 22:06:16      Dump the side-table for tag: 1 with group count: 8765 into file: file:/tmp/sangarebademba_mail/2c6ce05b-5694-44d0-993c-d5e6cbe9a6bb/hive_2026-01-03_22-05-52_556_7866330019839866641-1/-local-10003/HashTable-Stage-5/MapJoin-mapfile01--.hashtable2026-01-03 22:06:17      Uploaded 1 File to: file:/tmp/sangarebademba_mail/2c6ce05b-5694-44d0-993c-d5e6cbe9a6bb/hive_2026-01-03_22-05-52_556_7866330019839866641-1/-local-10003/HashTable-Stage-5/MapJoin-mapfile10--.hashtable (239064 bytes)
2026-01-03 22:06:17      End of local task; Time Taken: 7.068 sec.
Execution completed successfully
MapredLocal task succeeded
Launching Job 1 out of 1
Number of reduce tasks is set to 0 since there's no reduce operator
Starting Job = job_1767476335023_0001, Tracking URL = http://hadoop-master:8088/proxy/application_1767476335023_0001/
Kill Command = /home/sangarebademba_mail/hadoop/bin/mapred job -kill job_1767476335023_0001
Hadoop job information for Stage-5: number of mappers: 1; number of reducers: 0
2026-01-03 22:06:44,555 Stage-5 map = 0%, reduce = 0%
2026-01-03 22:06:54,123 Stage-5 map = 100%, reduce = 0%, Cumulative CPU 4.82 sec
MapReduce Total cumulative CPU time: 4 seconds 820 msec
Ended Job = job_1767476335023_0001
Moving data to local directory /home/sangarebademba_mail/resultats_enrichis_ia
MapReduce Jobs Launched:
Stage-Stage-5: Map: 1      Cumulative CPU: 4.82 sec      HDFS Read: 472648 HDFS Write: 2367604 SUCCESS
Total MapReduce CPU Time Spent: 4 seconds 820 msec
OK
Time taken: 64.047 seconds
hive> exit;
sangarebademba_mail@hadoop-master:~/ml-latest-small$ ls -lh /home/sangarebademba_mail/resultats_enrichis_ia/
total 2.3M
-rw-r--r-- 1 sangarebademba_mail sangarebademba_mail 2.3M Jan  3 22:06 000000_0
sangarebademba_mail@hadoop-master:~/ml-latest-small$ yarn node -list
2026-01-03 22:08:27,258 INFO client.DefaultNoHARMAFailoverProxyProvider: Connecting to ResourceManager at hadoop-master/10.128.0.3:8032
Total Nodes:2
      Node-Id      Node-State Node-Http-Address      Number-of-Running-Containers
hadoop-slave2:40793      RUNNING hadoop-slave2:8042      0
hadoop-slave1:33879      RUNNING hadoop-slave1:8042      0
sangarebademba_mail@hadoop-master:~/ml-latest-small$
```

FIGURE 3.2 – Preuve du fonctionnement des 2 Slaves dans YARN

3.2 Réseau et Sécurité

Pour permettre l'accès au Dashboard Web depuis internet, j'ai configuré une règle de pare-feu spécifique sur le VPC Google Cloud ouvrant le port ****8501****.

← Créer une règle de pare-feu

Les règles de pare-feu contrôlent le trafic entrant et sortant d'une instance. Par défaut, tout le trafic entrant vers votre réseau est bloqué. [En savoir plus](#)

Nom *

allow-streamlit



N'utilisez que des lettres minuscules, des chiffres et des traits d'union

Description



Journaux

L'activation des journaux de pare-feu peut générer un grand nombre de journaux et donc entraîner une augmentation des coûts dans Logging. [En savoir plus](#)



Activé



Désactivé

Réseau *

default



Priorité *

1000

[Comparer](#)



La priorité peut être comprise entre 0 et 65535

Sens du trafic ?



Entrée



Sortie

Action en cas de correspondance ?



Autoriser



Refuser

Cibles

Toutes les instances du réseau



Filtre source

Plages IPv4




FIGURE 3.3 – Configuration du Pare-feu pour l'accès Web

Chapitre 4

Traitement Big Data (Hive MapReduce)

4.1 Ingestion HDFS

Toutes les données (Movies, Ratings, Links, Descriptions TMDb) ont été transférées dans le système de fichiers distribué HDFS.



```
ssh.cloud.google.com/v2/ssh/projects/project-dcc4ce49-49b1-41c5-853/zones/us-central1-a/instances/hadc
SSH dans votre navigateur
IMPORTER UN FICHIER
TÉLÉCHARGER LE FICHIER

sangarebademba_mail@hadoop-master:~$ ls
hadoop
sangarebademba_mail@hadoop-master:~$ wget https://files.grouplens.org/datasets/movielens/ml-latest-small.zip
--2026-01-02 21:11:30-- https://files.grouplens.org/datasets/movielens/ml-latest-small.zip
Resolving files.grouplens.org (files.grouplens.org)... 128.101.96.204
Connecting to files.grouplens.org (files.grouplens.org)|128.101.96.204|:443... connected.
HTTP request sent, awaiting response... 200 OK
Length: 978202 (955K) [application/zip]
Saving to: 'ml-latest-small.zip'

ml-latest-small.zip      100%[=====] 955.28K  --.-KB/s  in 0.1s

2026-01-02 21:11:30 (6.98 MB/s) - 'ml-latest-small.zip' saved [978202/978202]

sangarebademba_mail@hadoop-master:~$ ls
hadoop ml-latest-small ml-latest-small.zip
sangarebademba_mail@hadoop-master:~$ unzip ml-latest-small.zip
Archive: ml-latest-small.zip
  creating: ml-latest-small/
  inflating: ml-latest-small/links.csv
  inflating: ml-latest-small/tags.csv
  inflating: ml-latest-small/ratings.csv
  inflating: ml-latest-small/README.txt
  inflating: ml-latest-small/movies.csv
sangarebademba_mail@hadoop-master:~$ ls
hadoop ml-latest-small ml-latest-small.zip
sangarebademba_mail@hadoop-master:~$ ls -l
total 964
drwxr-xr-x 13 sangarebademba_mail sangarebademba_mail 4096 Jan  1 22:05 hadoop
drwxr-xr-x  2 sangarebademba_mail sangarebademba_mail 4096 Sep 26 2018 ml-latest-small
-rw-rw-r-- 1 sangarebademba_mail sangarebademba_mail 978202 Dec  3 2019 ml-latest-small.zip
sangarebademba_mail@hadoop-master:~$ hdfs dfs -mkdir -p /input
sangarebademba_mail@hadoop-master:~$ hdfs dfs -put ml-latest-small/movies.csv /input/
sangarebademba_mail@hadoop-master:~$ hdfs dfs -put ml-latest-small/ratings.csv /input/
sangarebademba_mail@hadoop-master:~$ hdfs dfs -ls /input/
Found 2 items
-rw-r--r-- 2 sangarebademba_mail supergroup 494431 2026-01-02 21:13 /input/movies.csv
-rw-r--r-- 2 sangarebademba_mail supergroup 2483723 2026-01-02 21:14 /input/ratings.csv
sangarebademba_mail@hadoop-master:~$
```

FIGURE 4.1 – Ingestion des fichiers CSV dans HDFS


4.2 La "Grande Jointure" Hive

L'étape critique du projet a été de relier ces sources disparates. J'ai utilisé **Apache Hive** pour exécuter une jointure complexe (JOIN) entre 3 tables.

Requête SQL HIVE :

```
SELECT m.title, t.description, t.cover_url
FROM movies m
JOIN links l ON m.movieId = l.movieId
JOIN tmdb_data t ON l.tmdbId = t.tmdb_id;
```

Cette requête a déclenché un job **MapReduce** distribué sur le cluster.



```
Peak Reduce Physical memory (bytes)=243900416
Peak Reduce Virtual memory (bytes)=2547544064
Shuffle Errors
BAD_ID=0
CONNECTION=0
IO_ERROR=0
WRONG_LENGTH=0
WRONG_MAP=0
WRONG_REDUCE=0
File Input Format Counters
Bytes Read=498527
File Output Format Counters
Bytes Written=461100
2026-01-02 21:40:51,119 INFO streaming.StreamJob: Output directory: /cleaned_data
sangarebademba_mail@hadoop-master:~$ hdfs dfs -head /cleaned_data/part-00000
1 Toy Story 1995 Adventure|Animation|Children|Comedy|Fantasy
10 GoldenEye 1995 Action|Adventure|Thriller
100 City Hall 1996 Drama|Thriller
100044 Human Planet 2011 Documentary
100068 Comme un chef 2012 Comedy
100083 Movie 43 2013 Comedy
100106 Pervert's Guide to Ideology, The 2012 Documentary
100159 Sightseers 2012 Comedy
100163 Hansel & Gretel: Witch Hunters 2013 Action|Fantasy|Horror|IMAX
100194 Jim Jefferies: Fully Functional (EPIX) 2012 Comedy
100226 Why Stop Now 2012 Comedy|Drama
100277 Tabu 2012 Drama|Romance
1003 Extreme Measures 1996 Drama|Thriller
100302 Upside Down 2012 Drama|Romance|Sci-Fi
100304 Liability, The 2012 Action|Thriller
100306 Angst 1983 Drama|Horror
100326 Stand Up Guys 2012 Comedy|Crime
100383 Side Effects 2013 Crime|Drama|Mystery|Thriller
100390 Identity Thief 2013 Comedy|Crime
100397 ABCs of Death, The 2012 Horror
1004 Glimmer Man, The 1996 Action|Thriller
100487 Beautiful Creatures 2013 Drama|Fantasy|Romance
100498 Good Day to Die Hard, A 2013 Action|Crime|Thriller|IMAX
1005 D3: Thsangarebademba_mail@hadoop-master:~$
```

FIGURE 4.2 – Exécution du Job MapReduce (Map 100% / Reduce 100%)

Chapitre 5

IA Visualisation (Le Dashboard)

5.1 Interface Streamlit et Analyse des Résultats

Le résultat final est une application Web interactive complète. L'analyse des graphiques générés permet de dégager plusieurs tendances intéressantes sur le dataset MovieLens.

5.1.1 1. KPIs et Qualité

Le dashboard affiche un catalogue de près de **9 742 films** et plus de **100 000 votes** traités. Le tableau "Top 10" met en évidence que les films les mieux notés sont des classiques du cinéma (ex : *The Shawshank Redemption*, *The Godfather*).

5.1.2 2. Répartition des Genres et Activité

Le graphique circulaire révèle une domination claire du ****Drame (19.7%)**** et de la ****Comédie (17%)****. L'histogramme des utilisateurs montre que quelques "super-utilisateurs" (comme l'User 414) génèrent une grande partie du trafic.

5.1.3 3. Analyse Temporelle

La courbe de production montre une explosion du nombre de films dans la base de données à partir des années 1990.

5.2 Système de Recommandation NLP

J'ai intégré une brique d'Intelligence Artificielle utilisant le **Natural Language Processing (NLP)**. L'objectif est de recommander des films non pas basés sur les notes, mais sur la **similarité sémantique des résumés (descriptions)**.

Méthodologie :

- **TF-IDF** : Transformation des descriptions textuelles (récupérées via l'API) en vecteurs mathématiques.
- **Similarité Cosinus** : Calcul de l'angle entre les vecteurs de deux films pour trouver ceux qui racontent une histoire similaire.

L'interface permet ainsi de sélectionner un film (ex : *Spider-Man*) et de voir instantanément 5 films contextuellement proches avec leurs affiches.

Chapitre 6

Conclusion

Ce projet m'a permis de maîtriser la chaîne complète du Big Data :

1. **Infrastructure** : Gestion de clusters VMs et réseaux sur GCP.
2. **Stockage Calcul** : HDFS, YARN et MapReduce via Hive.
3. **Enrichissement** : Utilisation d'APIs externes et jointures de données hétérogènes.
4. **Valorisation** : Création d'un produit fini (Dashboard Web) intégrant de l'Intelligence Artificielle.

L'intégration réussie de la table de liaison (`links.csv`) pour fusionner des données historiques avec des données multimédias modernes, couplée à l'utilisation d'algorithmes de **similarité NLP** sur les descriptions, démontre la puissance de ces outils pour créer de la valeur ajoutée à partir de données brutes. De plus, je trouve que c'est la matière et les compétences qui se rapprochent le plus du Master en Big Data, je suis content d'avoir découvert et acquis des compétences en Hadoop. Merci pour la lecture.